UNEB (Universidade do Estado da Bahia)
Tópicos em Especiais em Engenharia de Software
Prof: Eduardo Manuel de Freitas Jorge

Projeto Integrador

Histórico de Revisão

Data	Versão	Descrição	Autor
22/02/2025	V1	Projeto Engenharia de Software com IA	Eduardo M F Jorge
22/04/2025	V2	Atualização do Nivelamento em NLTK. Ajustes de texto nos nivelamentos	Eduardo M F Jorge
26/05/2025	V3	Atualização Etapas do Projeto	Eduardo M F Jorge
09/07/2025	V4	Atualização do texto dos nivelamentos e exemplo de busca com retorno de artigos	Eduardo M F Jorge
26/04/2026	V5	Inclusão das etapas do projeto usando o processo Scrum e ajustes no projeto	Eduardo M F Jorge

O objetivo do trabalho é unificar conhecimentos de várias disciplinas que envolvem a concepção de um produto de software na área de Inteligência Artificial Generativa com Ciência de Dados. O processo utilizará fortemente a prototipação como mecanismo de especificação do produto e para a resolução de dúvidas de quais recursos tecnológicos devem ser aplicados. Visa-se estimular a busca por elementos teóricos e práticos para solução de um problema orientado por um professor. O produto deste projeto deverá ser um programa/software e um relatório técnico contendo toda a especificação do produto.

Descrição do Projeto: Um sistema de busca de informações dos pesquisadores baseado em Full-Text Search e LLM

Desenvolver um projeto para orquestrar o processo de ETL (Extração, Transformação e Carga) dos dados do currículo Lattes de pesquisadores, que estão em formato XML (eXtensible Markup Language), para uma base de dados relacional. Além disso, será realizada a conversão dos dados textuais em uma base de dados vetorial. Essa estrutura de dados servirá como suporte para uma camada de back-end, que disponibilizará uma API (Interface de Programação de Aplicações) para que a camada de front-end possa executar filtros e buscas semânticas nos títulos das produções científicas dos pesquisadores. Será construída uma API Rest que permite a interação entre a camada de back-end e front-end, garantindo um descolamento entre as camadas. Por último, a camada de back-end irá gerar um conjunto de arquivos CSV (Comma-Separated Values), que serão utilizados na ferramenta OLAP (Processamento Analítico Online) para a elaboração de análises e relatórios.

Exemplo de Sistemas Correlatos

Sistema	Descrição
https://simcc.uesc.br/	SIMCC – Sistema de Mapeamento de Competências da Bahia
https://somos.ufmg.br/	Sistema de mapeamento das competências da UFMG, com o objetivo de incrementar a interação

	da Universidade em áreas de pesquisa científica e tecnológica com instituições públicas e privadas.

Questões do Processo para o desenvolvimento do Projeto

Registrar e apresentar (10 minutos por equipe) na aula de quarta feira os artefatos de projeto, mas principalmente os registros de condução do processo Scrum

Realizar Sprints (Semanais iniciando e terminando todas as quartas-feiras

Iniciando o Sprint

Construção do Product Backlog

Objetivo: transformar a visão em itens de trabalho priorizados.

Resultado

Registros:

Product Backlog (em ferramenta como Trello, Jira ou similar)

Planejamento da Sprint (Sprint Planning)

Objetivo: definir o que será entregue na sprint.

Atividades:

- Selecionar itens do backlog
- Quebrar histórias em tarefas técnicas
- Estimar esforço (Story Points ou horas) com Planning Poker
- Definir a meta da sprint (Sprint Goal)

Resultado

Registros:

- Apresentar o Planning Poker, Quadro Kanban e Gráfico de Gráfico de Burndown Scrum

Execução e Finalização da Sprint (Desenvolvimento)

Atividades:

- Implementação das funcionalidades
- Testes (unitários e integrados)
- Integração contínua
- Atualização do quadro Kanban (To Do / Doing / Done)

Resultado

Registros:

- Como foi Daily Scrum (Reuniões Diárias)
- Fazer a Revisão da Sprint (Sprint Review) com o professor apresentando para a turma o que foi desenvolvido
- Validação dos artefatos com o professor
- Apresentar a Retrospectiva da Sprint (Sprint Retrospective) com os melhorias do processo para a próxima sprint

Ferramentas a serem utilizadas no projeto

- Git é um sistema de controle de versão distribuído que permite rastrear alterações em arquivos e colaborar em projetos de software de forma eficiente e organizada.
- Docker é uma plataforma que possibilita a criação e execução de aplicativos em contêineres, garantindo consistência em diferentes ambientes.
- Visual Studio Code, um editor de código-fonte da Microsoft, oferece amplas ferramentas para desenvolvimento, como destaque de sintaxe e integração com sistemas de controle de versão.
- Apache Hop é uma ferramenta de orquestração de dados que facilita a construção de fluxos de trabalho de ETL através de uma interface gráfica intuitiva.
- PostgreSQL, um banco de dados relacional robusto, ganha flexibilidade com a extensão pgvector, possibilitando o armazenamento e manipulação de vetores, especialmente em aplicações de aprendizado de máquina.
- HeidiSQL é uma ferramenta de administração de bancos de dados que permite gerenciar diversos sistemas, como MySQL, MariaDB e PostgreSQL, através de uma interface gráfica intuitiva.
- Python, em conjunto com o microframework Flask, é amplamente utilizado para desenvolver aplicações web escaláveis, integrando Modelos de Linguagem de Aprendizado de Máquina (LLM) para processamento de linguagem natural.
- Power BI permite a visualização de dados e criação de dashboards interativos, transformando dados em insights valiosos para decisões empresariais.
- Next.js permite a criação de sites dinâmicos com renderização do lado do servidor.

Arquitetura da Solução

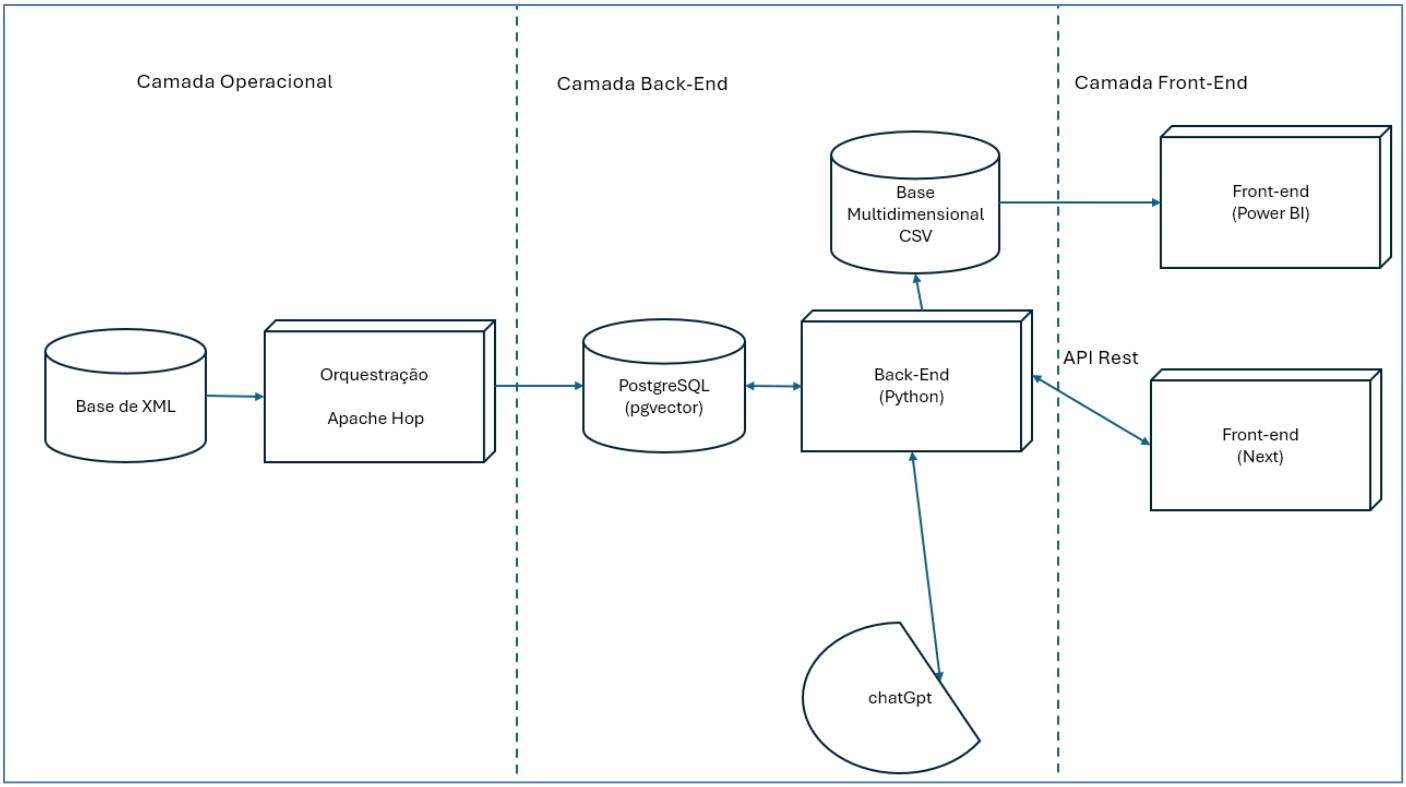

Exemplo de Busca a ser elaborada

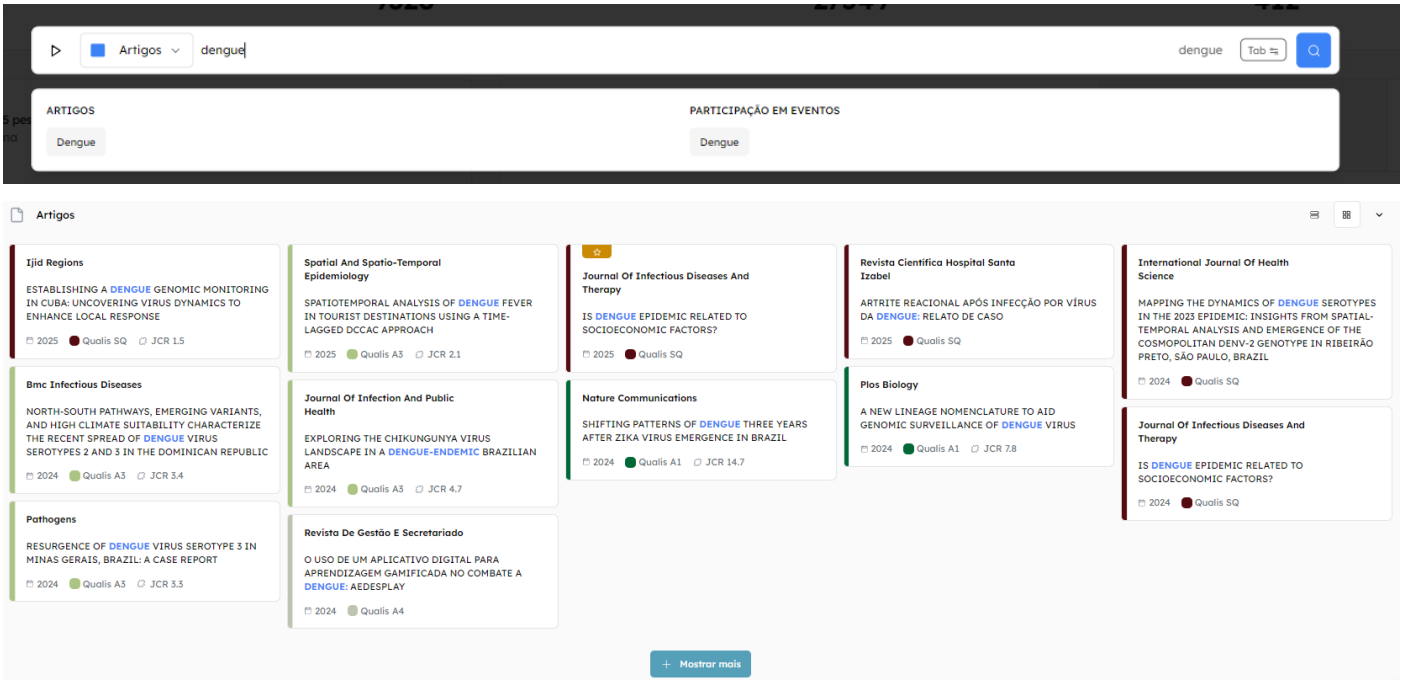

Etapa de Nivelamento (Realizada de forma individual)

Item	Descrição	Entrega
Pipelines de Dados com Apache HOP	Esta atividade simula um processo de ETL (Extração, Transformação e Carga) utilizando a ferramenta Apache Hop. De forma prática, será demonstrado como orquestrar cargas de bancos de dados operacionais por meio de pipelines e fluxos de dados visuais, bem documentados e intuitivos. Para exemplificar a aplicação da	No Git com a instalação do projeto de forma correta

	ferramenta, será desenvolvido um caso que ilustra a extração de dados do Currículo Lattes. Ao final, esses dados serão importados para o Power BI, onde serão visualizados em forma de gráfico, permitindo uma análise clara e eficaz das informações extraídas.	
Busca em banco de dados textual	Fazer o tutorial https://www.infoq.com/br/articles/postgresql-fts/	Script no Git com comentários Elaborar um exemplo com as tabelas Pesquisadores e Produções que simule os mesmos exemplos do tutorial. Esse tutorial deve ser publicado no linkedin.
Introdução ao Processamento de Linguagem Natural usando Python	Fazer até o 5.4.1.1. Construindo um tagger https://www.facom.ufu.br/~wendelmelo/terceiros/tutorial_nltk.pdf	Código em Python no Git Elaborar alguns exemplos e explicar o código também em um artigo do linkedin.
Tutorial para criação de Back-end com API em Json	Fazer o tutorial do FastAPI https://www.hashtagtreinamentos.com/criar-api-com-fastapi-em-python?gad_source=1&gclid=Cj0KCQjwm7q-BhDRARIsACD6-fXObLBM0N9MmiB937JZEcvUvwP8TykgVFwbENKNIPPIL9POxT5vbLEaAusqEALw_wcB **https://github.com/meirelesgc/treinamento-simcc/blob/tutorial/README.md** **git clone https://github.com/meirelesgc/treinamento-simcc.git** **Depois** **git checkout tarefa**	Código em Python no Git Atualizar o projeto para lidar com CRUD das tabelas de pesquisadores e produções; Criar um função para listar as produções de um determinado pesquisador Explicar o código em um artigo no linkedin.
Tutorial para criação de Front-end para consumir a API em Json	**https://github.com/rafaelontour/tutorial_next_ic**	Código em Next ou React no Git. Altera o código para publicar informações dos pesquisadores e

		produções do nivelamento anterior.
Langchain: Técnicas de Engenharia de Prompt e Utilização de Embeddings	**Fazer o tutorial** **https://docs.langchain.com/oss/python/langchain/knowledge-base** **Fazer o tutorial** **https://docs.langchain.com/oss/python/langchain/rag**	Desenvolvimento de um Projeto Python Integrado ao PostgreSQL com a Extensão pgvector para Dados Vetoriais. Alterar o nivelamento anterior fazendo uso do langchain na camada de back-end. Demonstrar essa funcionalidade na camada de front-end.
Sprint I: Projeto	**Construção do Product Backlog** **Análise e Especificação do Projeto** Documento com a Descrição do Sistema, Especificação de Requisitos (Histórias do Usuário com a definição de critérios de aceitação), Caso de Uso e Projeto Arquitetural Protótipo de Média Fidelidade Esquema do Banco de Dados Entidade Relacionamento	Entrega da Análise e Especificação do Projeto Colocar os documentos no Git
Sprint II: Camada de Orquestração de Dados	**Apache Hop** ETL dos dados XML do currículo lattes para o banco de dados relacional e Integração com outras bases de dados (ex. Qualis CAPES, DOI (*digital identifier of an object*), Grupos de Pesquisa, JCR (*Journal Citation Reports*), etc)	Entrega Código do Apache Hop no Git
Sprint III: Camada de Back-End	**Camada de Back-End em Python** Desenvolver funcionalidade de busca textual sobre as produções do pesquisador Desenvolver busca Semântica utilizando IA Generativa Desenvolver programa de teste orientado a caractere para demonstrar solução	Entrega do Código em Python no Git Documentação da API

	Desenvolver API Rest Json para a camada de aplicação ser utilizada pela camada de front-end Web Criar uma página Web com a documentação da API	
Sprint IV: Camada de Front-End	**Camada de Front-End em Next** Desenvolver camada de interface em Next utilizando a API da etapa anterior	Entrega do Código em Next no Git Criar um vídeo demonstrando a solução
Sprint V	Alterar a camada de back-end para geração de dados analíticos em CSV Apresentar um painel com gráficos e tabelas com as informações analíticas. Criar as dimensões Quadrienal-Ano, Pesquisador e o fato relativo a produção científica.	Entrega através do arquivo Power BI. Explicar a solução em um artigo no linkedin.
Apresentação Final	Apresentação Final	Apresentar todos os artefatos do projeto